

Reduce n-dim to k-dim  
Date

Dataset:  $\{x^{(i)}; i=1, \dots, m\}$

$$\vec{x}^{(i)} = \begin{pmatrix} x_1^{(i)} \\ \vdots \\ x_n^{(i)} \end{pmatrix}$$

$\Rightarrow$  为使标准化不同分量的均值、方差。

$$\mu = \frac{1}{m} \sum_{i=1}^m \vec{x}^{(i)}$$

对每个分量  $x_j^{(i)} \leftarrow x_j^{(i)} - \mu$ . (使得均值  $\mu = 0$ )

这种  
处理  
称为  
“白化”


$$\sigma_j^2 = \frac{1}{m} \sum_{i=1}^m (x_j^{(i)})^2$$

对每个分量  $x_j^{(i)} \leftarrow \frac{x_j^{(i)}}{\sigma_j}$  (使得方差  $\sigma_j^2 = 1$ )

( $\rightarrow$  空间)

目标：找到一个  $k$  维超平面 ( $-$  组基  $\vec{u}_1, \dots, \vec{u}_k$ )

s.t.: 全体数据点在该超平面上投影 方差最大。



$$\Sigma = \frac{1}{m} \sum_{i=1}^m \vec{x}^{(i)} \vec{x}^{(i)T}$$

$$\Sigma = \begin{pmatrix} \text{cov}(1,1) & \dots & \text{cov}(1,n) \\ \text{cov}(2,1) & \dots & \vdots \\ \vdots & \ddots & \text{cov}(n,n) \end{pmatrix}$$

$\vec{u}_1, \vec{u}_2, \dots, \vec{u}_k$  为  $\Sigma$  的特征向量

其对应的值越大，则说明对应下柱的特征之间相关性越高

事：找到  $k$ -dim 子空间  $\text{im } \tilde{f}_b$  - 组成  $\tilde{u}_1, \dots, \tilde{u}_k$  在  $\tilde{f}_b$

将原坐标系表示  $x^{(i)} = \begin{pmatrix} x_1^{(i)} \\ \vdots \\ x_n^{(i)} \end{pmatrix}$  投影到这个  $k$ -dim 子空间

新坐标系

2. 即用这样新坐标表示：

$$y^{(i)} = \begin{pmatrix} \vec{u}_1^T \vec{x}^{(i)} \\ \vec{u}_2^T \vec{x}^{(i)} \\ \vdots \\ \vec{u}_k^T \vec{x}^{(i)} \end{pmatrix} \in \mathbb{R}^k.$$

映射

线性变换  $\Sigma: \mathbb{R}^n \rightarrow \mathbb{R}^k$ .

原坐标系：

$$\vec{\xi}_1 = \begin{pmatrix} 1 \\ 0 \\ \vdots \\ 0 \end{pmatrix}, \vec{\xi}_2 = \begin{pmatrix} 0 \\ 1 \\ \vdots \\ 0 \end{pmatrix}, \dots, \vec{\xi}_n$$

RJ

新坐标系

$x^{(i)}$  是在下文下的坐标

线性映射后坐标： $\vec{u}_1, \vec{u}_2, \dots, \vec{u}_k$

$y^{(i)}$  是在下文下的坐标